Informe Final
Laboratorio 3 – Análisis Integral de Datos para Regresión y Clasificación

1. Introducción

En este trabajo se realizó un análisis integral de datos sobre dos bases con objetivos distintos: una orientada a clasificación y otra a regresión. El proceso incluyó la organización de la información en SQLite, la ejecución de consultas SQL, el análisis exploratorio de datos, el tratamiento de valores faltantes, la aplicación de pruebas estadísticas y la visualización de resultados mediante una aplicación desarrollada en Streamlit.

La primera base corresponde a un problema de clasificación relacionado con enfermedad renal crónica, mientras que la segunda aborda un problema de regresión asociado a cargos médicos. A partir de ambas se buscó identificar patrones relevantes, describir el comportamiento de las variables, explorar relaciones entre ellas y obtener hallazgos estadísticamente sustentados. El trabajo combinó una etapa analítica más detallada en notebooks con una etapa de visualización resumida e interactiva en la aplicación final.

2. Descripción de los datos

Se trabajó con dos conjuntos de datos claramente diferenciados. La base de clasificación contiene 400 observaciones y está orientada al estudio de la enfermedad renal crónica. La variable objetivo es class, con dos categorías: ckd, con 250 registros, y notckd, con 150 registros. Esta distribución muestra que la base no está completamente balanceada, lo cual es importante porque puede influir en la interpretación de los patrones observados entre los grupos. La edad promedio general de los pacientes es de 51.48 años, y al separar por clase se observa que los pacientes con ckd presentan una edad promedio de 54.54 años, mientras que los pacientes notckd tienen una edad promedio de 46.52 años. Además, 147 pacientes presentan hipertensión, variable que resulta clínicamente relevante dentro del análisis.

La base de regresión contiene 1338 observaciones y tiene como variable respuesta charges, que representa cargos médicos. El valor promedio de esta variable es de 13270.42. Al agrupar por la variable smoker, se encontró que los no fumadores tienen un promedio de 8434.27, mientras que los fumadores alcanzan un promedio de 32050.23, diferencia que evidencia un contraste importante entre ambos grupos. Al analizar la variable sex, los hombres presentan un promedio de

13956.75 y las mujeres de 12569.58. Adicionalmente, la base contiene 274 personas clasificadas como fumadoras. Estos resultados permiten entender desde el inicio que el hábito de fumar podría desempeñar un papel importante en la variación de los costos médicos.

En términos generales, ambas bases combinan variables numéricas y categóricas. En la base de clasificación predominan variables clínicas asociadas al estado de salud del paciente, mientras que en la base de regresión aparecen variables demográficas y de hábitos que permiten explicar el comportamiento de los cargos médicos.

3. Proceso de limpieza

El proceso de limpieza se centró en revisar la estructura de las bases, validar los tipos de variables e identificar la presencia de datos faltantes antes de desarrollar el análisis estadístico.

En la base de clasificación se detectaron valores faltantes en diferentes variables numéricas y categóricas, por lo que fue necesario aplicar métodos de imputación antes de profundizar en las pruebas de dependencia y asociación. Esta etapa fue especialmente importante porque varias de las variables clínicas con mayor interés analítico presentaban ausencias que podían afectar tanto la descripción de los datos como la estabilidad de los resultados posteriores.

En la base de regresión no se identificaron valores faltantes, por lo cual no fue necesario realizar imputación. Esto permitió trabajar directamente con la información disponible para el análisis descriptivo, las correlaciones y las pruebas estadísticas.

Además de la revisión de faltantes, se verificó que las tablas almacenadas en SQLite coincidieran con la estructura analizada posteriormente en los notebooks y en la aplicación. De esta manera, el análisis mantuvo consistencia entre la etapa de almacenamiento, la exploración y la visualización final.

4. Análisis exploratorio

El análisis exploratorio permitió comprender la forma general de las distribuciones, identificar posibles valores atípicos y reconocer relaciones relevantes entre variables antes de aplicar pruebas estadísticas.

4.1 Base de clasificación

En la base de clasificación, la distribución de la variable objetivo mostró una mayor presencia de casos ckd frente a notckd, lo que da una primera idea del comportamiento de la población estudiada. Al revisar las estadísticas descriptivas y los gráficos por variable, se observó que varias medidas clínicas presentan diferencias notorias entre pacientes

con y sin enfermedad renal crónica. La edad, por ejemplo, mostró un promedio más alto en el grupo ckd, lo que sugiere una mayor frecuencia de esta condición en pacientes de mayor edad.

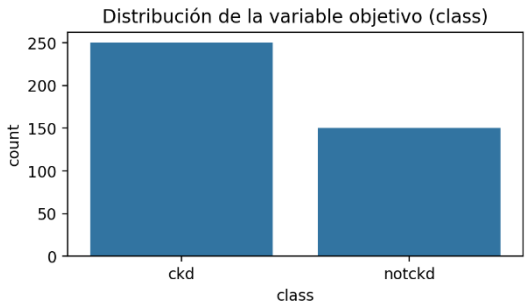

Fig. 1. Distribución de la variable objetivo class

Entre las variables más relevantes del análisis destacó hemo, ya que sus distribuciones y boxplots mostraron una separación clara entre grupos. Los pacientes con enfermedad renal crónica tienden a presentar valores más bajos de hemoglobina, mientras que el grupo notckd concentra valores relativamente más altos. Esta diferencia no solo fue visible de forma gráfica, sino que más adelante también se confirmó mediante pruebas estadísticas.

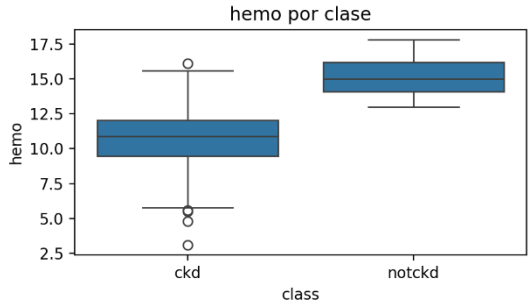

Fig. 2. Boxplot de hemo según class

Otra relación importante apareció entre hemo y sc. La inspección de estas variables mostró una relación inversa: a mayores niveles de creatinina sérica, los valores de hemoglobina tienden a disminuir. Desde el punto de vista clínico, este comportamiento resulta coherente y fortalece la interpretación de que ambas variables contienen información útil para caracterizar el estado del paciente.

4.2 Base de regresión

En la base de regresión, la variable charges mostró una distribución claramente asimétrica hacia la derecha. La mayor parte de las observaciones se concentra en valores relativamente bajos, pero existe un grupo de registros con cargos considerablemente más altos, lo que sugiere la presencia de observaciones extremas y una alta dispersión en la variable respuesta.

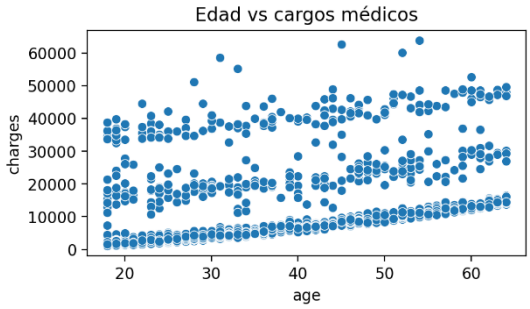

Fig. 3 Scatter plot de age vs charges

Las variables age y bmi presentaron distribuciones más estables que charges, aunque con características distintas. En el caso de bmi, se

observaron algunos valores atípicos altos, mientras que children mostró una concentración importante en valores bajos, especialmente entre 0 y 2. En conjunto, esto indica que no todas las variables aportan variabilidad en la misma magnitud y que charges concentra gran parte de la heterogeneidad del conjunto de datos.

El análisis de correlación mostró que no existen relaciones lineales muy fuertes entre las variables numéricas, pero sí se evidenció una correlación positiva moderada entre age y charges, lo que sugiere que los cargos médicos tienden a aumentar con la edad. También se observó una relación positiva más débil entre bmi y charges, lo que permite considerar que el índice de masa corporal podría influir, aunque en menor medida, sobre el costo médico.

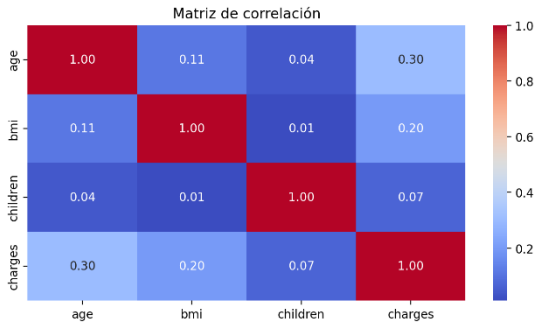

Fig. 4. Matriz de correlación de las variables numéricas de la base de regresión

Los gráficos comparativos por categorías mostraron uno de los hallazgos más claros de toda la base: los fumadores presentan cargos médicos considerablemente superiores a los no fumadores. Esta diferencia apareció tanto en los promedios obtenidos por SQL como en la exploración gráfica, lo que anticipaba un resultado fuerte al aplicar la prueba estadística correspondiente.

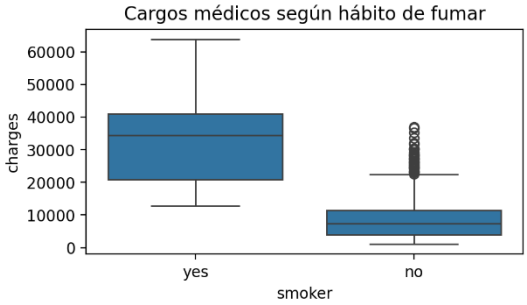

Fig. 5. Boxplot de charges según smoker

5. Métodos de imputación utilizados

La imputación se aplicó únicamente en la base de clasificación, ya que fue la única que presentó valores faltantes. Para evaluar cuál método resultaba más conveniente, se compararon tres enfoques: imputación simple, imputación por vecinos más cercanos (KNN) e imputación iterativa.

La imputación simple reemplazó los faltantes numéricos con una medida de tendencia central y los categóricos con la moda. Aunque este método es fácil de aplicar y permite completar rápidamente la base, su principal limitación es que tiende a reducir la variabilidad de los datos y a suavizar de forma excesiva ciertas distribuciones.

La imputación iterativa ofreció una alternativa más elaborada al estimar los valores faltantes a partir de

relaciones entre variables. Sin embargo, al comparar gráficamente los resultados, en algunas variables se observaron cambios menos consistentes respecto a la forma original de la distribución.

El método KNN fue el que mostró el comportamiento más estable. En las comparaciones visuales conservó mejor la forma general de las distribuciones, mantuvo de manera más razonable la dispersión y preservó con mayor fidelidad el comportamiento de valores extremos. Por esta razón, KNN se seleccionó como el método más adecuado para la base de clasificación.

Esta elección no se basó únicamente en completar los datos faltantes, sino en conservar lo mejor posible la estructura original de la información, de modo que las conclusiones posteriores no quedaran distorsionadas por el método de imputación empleado.

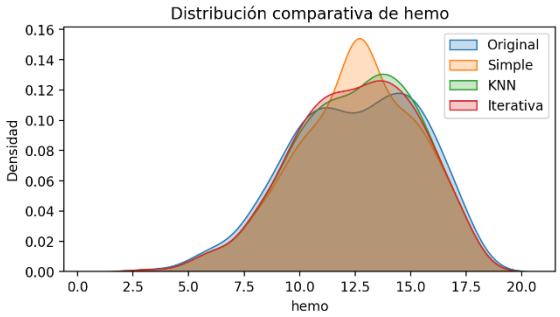

Fig. 6. Distribución comparativa de la variable hemo para los métodos de imputación original, simple, KNN e iterativa

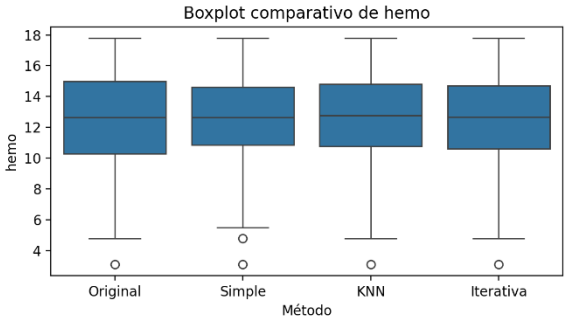

Fig. 7. Boxplot comparativo de la variable hemo para los métodos de imputación original, simple, KNN e iterativa.

6. Resultados de pruebas estadísticas

Las pruebas estadísticas se aplicaron con el objetivo de examinar relaciones de asociación y dependencia entre variables categóricas, numéricas y mixtas. En la base de clasificación se trabajó con Chi-cuadrado, correlación de Spearman y Kruskal-Wallis. En la base de regresión se aplicaron Chi-cuadrado, correlación de Pearson y ANOVA. Las variables seleccionadas fueron las que mostraron mayor relevancia dentro del análisis exploratorio y también las más útiles para interpretar el comportamiento de cada problema.

6.1 Base de clasificación

La prueba Chi-cuadrado entre htn y class arrojó un estadístico de 135.48 y un p-valor de 2.596e-31. Este resultado indica una asociación estadísticamente significativa entre la hipertensión y la variable objetivo. En términos prácticos, la presencia de

hipertensión está relacionada con la clasificación de los pacientes, por lo que htn se comporta como una variable categórica de gran interés dentro del problema de clasificación.

La correlación de Spearman entre hemo y sc produjo un coeficiente de -0.7265 con un p-valor de 1.588e-56. La magnitud del coeficiente y su signo negativo evidencian una relación monotónica inversa fuerte: a medida que aumenta la creatinina sérica, la hemoglobina tiende a disminuir. Este hallazgo es importante porque muestra una dependencia clara entre dos variables clínicas centrales del conjunto de datos.

La prueba de Kruskal-Wallis para hemo según class produjo un estadístico de 222.01 y un p-valor de 3.304e-50. Esto confirma que existen diferencias estadísticamente significativas en los niveles de hemoglobina entre los grupos ckd y notckd. En consecuencia, hemo no solo presenta diferencias visuales entre clases, sino que también constituye una variable con capacidad real de discriminación dentro del problema analizado.

En conjunto, estos resultados refuerzan la idea de que la enfermedad renal crónica en esta base está relacionada con alteraciones clínicas bien definidas y no con diferencias aleatorias entre grupos.

6.2 Base de regresión

La prueba Chi-cuadrado entre smoker y sex produjo un estadístico de 7.3929 y un p-valor de 0.0065. Esto indica que existe asociación estadísticamente significativa entre ambas variables, por lo que la distribución del hábito de fumar no es independiente del sexo dentro de la muestra analizada.

La correlación de Pearson entre age y charges arrojó un coeficiente de 0.2990 con un p-valor de 4.887e-29. Aunque la intensidad de la relación puede considerarse moderada, el resultado es claramente significativo y permite afirmar que a mayor edad tienden a observarse cargos médicos más altos. Esto sugiere que la edad es una variable relevante para explicar parte del comportamiento de la variable respuesta.

Finalmente, el análisis de varianza (ANOVA) aplicado a charges según smoker produjo un estadístico F de 2177.61 y un p-valor de 8.271e-283. Este resultado muestra una diferencia extremadamente significativa entre fumadores y no fumadores en términos de cargos médicos. Más allá de la significancia estadística, la diferencia tiene una interpretación práctica fuerte: el hábito de fumar está asociado con un aumento considerable en los costos médicos observados en la base.

En síntesis, la base de regresión muestra que charges no se comporta de manera aleatoria frente a las

variables analizadas, sino que responde con claridad a factores como la edad y, especialmente, al hábito de fumar.

7. Conclusiones

El análisis realizado permitió obtener una visión amplia de dos problemas distintos a partir de una combinación de consultas SQL, análisis exploratorio, imputación, pruebas estadísticas y visualización interactiva.

En la base de clasificación se identificaron relaciones consistentes entre variables clínicas y la presencia de enfermedad renal crónica. La hipertensión mostró asociación significativa con la variable objetivo, la creatinina sérica y la hemoglobina presentaron una relación inversa fuerte, y la hemoglobina mostró diferencias significativas entre pacientes con y sin enfermedad renal crónica. Además, dado que esta base presentaba valores faltantes, la comparación de métodos de imputación resultó fundamental. Entre los métodos evaluados, KNN fue el que mejor conservó la estructura de los datos y por ello se adoptó como la opción más adecuada.

En la base de regresión, los resultados mostraron que los cargos médicos se relacionan de manera importante con ciertas características de los pacientes. La edad presentó una asociación positiva significativa con charges, pero el hallazgo más contundente fue la diferencia entre fumadores y no fumadores, observada tanto en los promedios descriptivos como en el ANOVA. Esto indica que el hábito de fumar constituye uno de los factores más influyentes sobre la variación de los cargos médicos dentro de este conjunto de datos.

En términos generales, el trabajo permitió no solo caracterizar ambas bases desde una perspectiva descriptiva y estadística, sino también integrar los hallazgos en una aplicación en Streamlit que resume de manera clara los resultados principales del análisis.